ĐẠI HỌC QUỐC GIA THÀNH PHỐ HỒ CHÍ MINH
TRƯỜNG ĐẠI HỌC BÁCH KHOA
KHOA KHOA HỌC VÀ KĨ THUẬT MÁY TÍNH



ĐỀ XUẤT A1.1

Học sâu và ứng dụng trong thị giác máy tính

CNN vs Transformer trên tập ảnh lớn

SVTH: Đàm Đức Huy (2670293)

TP. HỒ CHÍ MINH, 11/2026

Contents

1 Mục tiêu **1**

2 Tổng quan bộ dữ liệu CIFAR-100 **1**
2.1 Đặc điểm dữ liệu 1
2.2 Phân chia train, validation và test 2
2.3 Định hướng tiền xử lý dữ liệu 3

3 Mô hình được lựa chọn **3**
3.1 Mạng tích chập ResNet-18 3
3.2 Vision Transformer Tiny 3

4 Kế hoạch huấn luyện và so sánh **3**
4.1 Các chế độ huấn luyện 3
4.2 Ma trận thí nghiệm 4
4.3 Tiêu chí đánh giá dự kiến 4

5 Kết luận và kế hoạch tiếp theo **4**

Danh sách hình vẽ

1 Mười hai ảnh mẫu được lấy ngẫu nhiên từ CIFAR-100, kèm tên lớp và mã nhãn. Hình được trích trực tiếp từ kết quả notebook `co5085-a1-cifar100-classification.ipynb` của nhóm (seed 42). 2

Danh sách bảng

1 Kết quả phân chia CIFAR-100 theo notebook Kaggle. 2
2 Kế hoạch các cấu hình để triển khai trong A1.2. 4

1 Mục tiêu

Phân loại ảnh là một trong những bài toán nền tảng của thị giác máy tính, trong đó hệ thống cần gán nhãn cho một ảnh dựa trên đặc trưng thị giác. Các mạng tích chập (Convolutional Neural Networks – CNN) thường khai thác cấu trúc không gian cục bộ thông qua phép tích chập, trong khi Vision Transformer (ViT) mô hình hóa quan hệ giữa các vùng ảnh bằng cơ chế self-attention. Sự khác biệt về kiến trúc đặt ra câu hỏi về mức độ phù hợp của từng mô hình với bộ dữ liệu ảnh có độ phân giải thấp và số lớp lớn.

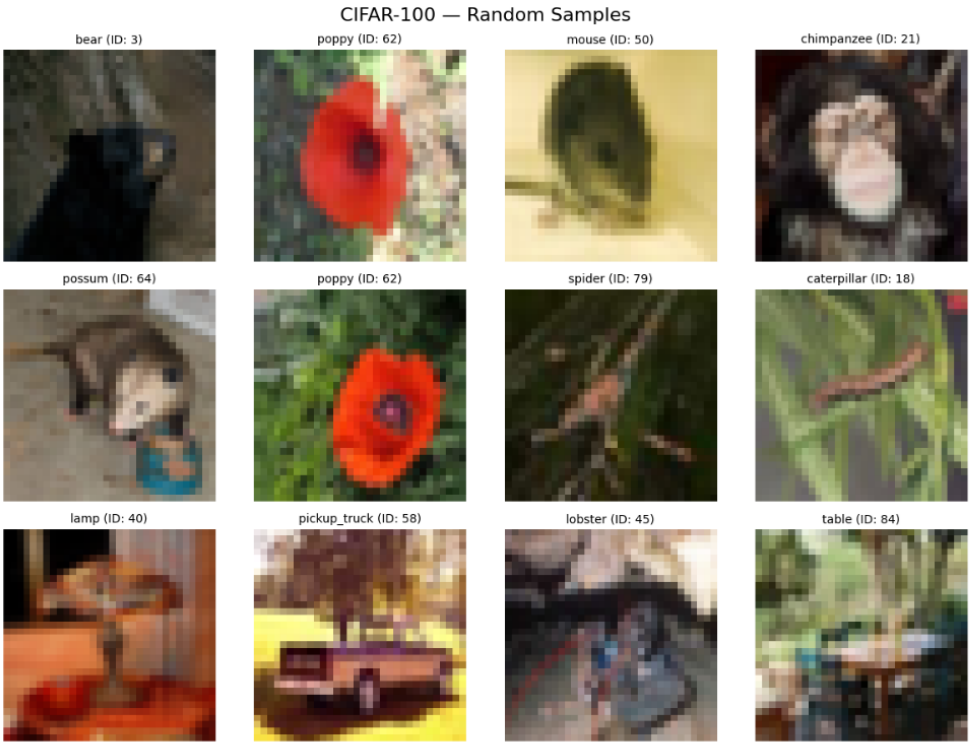
Bài tập lớn A1 nghiên cứu sự khác biệt giữa hai họ mô hình, đồng thời phân tích ảnh hưởng của cách khởi tạo trọng số và chiến lược cập nhật tham số. Trong giai đoạn A1.1, nhóm xác lập bộ dữ liệu và quy trình thực nghiệm, tạo cơ sở để triển khai và đánh giá ở A1.2. Mục tiêu cụ thể gồm: (i) xây dựng quy trình phân chia và tiền xử lý dữ liệu có thể tái lập; (ii) lựa chọn một kiến trúc CNN và một kiến trúc Transformer phù hợp với tài nguyên GPU; (iii) thiết kế các thí nghiệm so sánh huấn luyện từ đầu, dùng trọng số pretrained và ba chế độ freeze/fine-tune; (iv) xác định tiêu chí đánh giá kết quả và chi phí huấn luyện. Báo cáo này trình bày thiết kế, chưa kết luận về độ chính xác của mô hình.

2 Tổng quan bộ dữ liệu CIFAR-100

2.1 Đặc điểm dữ liệu

Nhóm lựa chọn **CIFAR-100**, bộ dữ liệu phân loại ảnh công khai được phát triển bởi Krizhevsky và cộng sự. Bộ dữ liệu có **60.000 ảnh RGB**, độ phân giải **32 $\times$ 32 pixel**, được gán nhãn theo **100 lớp chi tiết** (fine classes). Mỗi lớp có 600 ảnh. CIFAR-100 cung cấp sẵn 50.000 ảnh huấn luyện và 10.000 ảnh kiểm tra, tương ứng 500 ảnh train và 100 ảnh test cho mỗi lớp.

Các lớp bao gồm nhiều nhóm đối tượng như động vật, phương tiện, cây cối và vật dụng thường ngày. Việc phân biệt 100 lớp từ ảnh nhỏ khiến bài toán có độ khó phù hợp hơn so với các tập dữ liệu đơn giản được sử dụng ở các bài tập trước. Một hạn chế đáng chú ý là độ phân giải 32 $\times$ 32 khá thấp đối với các mô hình ViT thường được pretrained ở độ phân giải lớn; do đó, quy trình resize và tiền xử lý cần được công bố rõ.



Hình 1: *Mười hai ảnh mẫu được lấy ngẫu nhiên từ CIFAR-100, kèm tên lớp và mã nhãn. Hình được trích trực tiếp từ kết quả notebook* `co5085-a1-cifar100-classification.ipynb` *của nhóm (seed 42).*

Nguồn dữ liệu chính thức: `https://www.cs.toronto.edu/~kriz/cifar.html`. Nhóm sử dụng `torchvision.datasets.CIFAR100` để tải dữ liệu. Khi công bố mã nguồn, nhóm chỉ chia sẻ mã tải và các chỉ số phân chia, không mặc định phân phối lại toàn bộ ảnh; điều khoản sử dụng tại nguồn phát hành cần được kiểm tra trước khi tái phân phối.

2.2 Phân chia train, validation và test

Để bảo đảm phép so sánh có thể tái lập, nhóm giữ nguyên tập test chính thức gồm 10.000 ảnh. Từ 50.000 ảnh train gốc, nhóm tách **90% cho train và 10% cho validation** bằng hàm `train_test_split`, với `random_state = 42` và `stratify` theo nhãn lớp. Nhờ vậy, mỗi trong 100 lớp có số mẫu đồng đều ở cả ba tập.

Bảng 1: *Kết quả phân chia CIFAR-100 theo notebook Kaggle.*

Tập dữ liệu	Số ảnh	Tỷ lệ toàn bộ	Ảnh/lớp	Mục đích
Train	45.000	75,00%	450	Học tham số
Validation	5.000	8,33%	50	Chọn checkpoint/cấu hình
Test	10.000	16,67%	100	Đánh giá cuối
Tổng	60.000	100%	600	

Notebook đã in ra số lượng train/validation/test tương ứng 45.000/5.000/10.000, kiểm tra ví dụ lớp `apple` lần lượt có 450/50/100 ảnh và xác nhận hai tập train–validation không có chỉ số trùng nhau. Danh sách chỉ số được lưu dưới tên `cifar100_split_seed42.npz` nhằm tái sử dụng cho tất cả các cấu hình CNN và Transformer. Tập test được giữ riêng và không sử dụng để lựa chọn siêu tham số.

2.3 Định hướng tiền xử lý dữ liệu

Trong giai đoạn huấn luyện A1.2, ảnh train dự kiến được chuẩn hóa, thay đổi kích thước cho phù hợp với đầu vào của từng mô hình và áp dụng augmentation, chẳng hạn random crop và horizontal flip. Ảnh validation/test chỉ áp dụng các phép biến đổi xác định. Với checkpoint pretrained, mean/std và kích thước ảnh sẽ theo cấu hình preprocessing của checkpoint cụ thể. Đầu vào có thể khác nhau về kích thước giữa CNN và ViT, nhưng mọi thí nghiệm phải giữ nguyên tập mẫu, nhãn và chỉ số chia dữ liệu. Các giá trị transform chi tiết sẽ được khóa trước khi chạy thực nghiệm chính thức.

3 Mô hình được lựa chọn

3.1 Mạng tích chập ResNet-18

ResNet-18 được chọn làm đại diện CNN nhờ cấu trúc residual connections giúp truyền gradient qua các tầng sâu và chi phí huấn luyện tương đối thấp. Nhóm dự kiến dùng triển khai từ `torchvision`, thay tầng phân loại cuối bằng một lớp tuyến tính có 100 đầu ra. ResNet-18 đóng vai trò baseline để khảo sát khả năng học đặc trưng từ đầu và hiệu quả chuyển giao từ trọng số pretrained trên ImageNet.

3.2 Vision Transformer Tiny

ViT-Tiny được chọn làm đại diện Transformer. ViT chia ảnh thành các patch, mã hóa chúng thành chuỗi token và học quan hệ giữa các token bằng self-attention. Nhóm dự kiến sử dụng triển khai trong thư viện `timm`, thay classification head để dự đoán 100 lớp. Vì số tham số, kích thước patch và đặc điểm pretrained phụ thuộc chính xác vào checkpoint, nhóm sẽ ghi lại tên model ID, độ phân giải, patch size và nguồn trọng số khi triển khai A1.2. Việc chọn biến thể Tiny nhằm giảm chi phí thực nghiệm trong môi trường Kaggle GPU.

4 Kế hoạch huấn luyện và so sánh

4.1 Các chế độ huấn luyện

Các cấu hình được xây dựng trên hai yếu tố: (1) *khởi tạo trọng số* – từ đầu (random initialization) hoặc pretrained; (2) *phạm vi cập nhật tham số* – freeze toàn bộ backbone, freeze một phần hoặc fine-tune toàn bộ. Với pretrained, tầng phân loại mới luôn được huấn luyện cho 100 lớp CIFAR-100.

Ở chế độ **from scratch**, trọng số mô hình được khởi tạo ngẫu nhiên và toàn bộ mô hình được huấn luyện trên CIFAR-100. Với **freeze backbone**, tất cả tham số trích xuất đặc trưng bị cố định, chỉ classification head được học. Ở **partial freeze**, nhóm cố định các tầng đầu và tinh chỉnh các tầng sau cùng head; phạm vi tầng sẽ được xác định thống nhất trong code. Ở **full fine-tune**, toàn bộ backbone và head được cập nhật bằng dữ liệu mục tiêu.

4.2 Ma trận thí nghiệm

Bảng 2: *Kế hoạch các cấu hình để triển khai trong A1.2.*

Mã	Kiến trúc	Trọng số ban đầu	Chiến lược cập nhật
C1	ResNet-18	Ngẫu nhiên	From scratch
C2	ResNet-18	Pretrained	Freeze backbone
C3	ResNet-18	Pretrained	Partial freeze
C4	ResNet-18	Pretrained	Full fine-tune
T1	ViT-Tiny	Ngẫu nhiên	From scratch
T2	ViT-Tiny	Pretrained	Freeze backbone
T3	ViT-Tiny	Pretrained	Partial freeze
T4	ViT-Tiny	Pretrained	Full fine-tune

Tám cấu hình giúp đánh giá đồng thời sự khác biệt CNN–Transformer, hiệu ứng pretrained so với khởi tạo ngẫu nhiên và tác động của các mức freeze. Các thí nghiệm sẽ dùng cùng split cố định (seed 42), ghi rõ optimizer, learning rate, batch size, epoch, tiêu chí chọn checkpoint và cấu hình GPU. Trong trường hợp giới hạn tài nguyên, nhóm sẽ ưu tiên đảm bảo tối thiểu các so sánh bắt buộc trong đề và báo cáo minh bạch mọi cấu hình không hoàn thành.

4.3 Tiêu chí đánh giá dự kiến

Hiệu năng phân loại được đo bằng accuracy trên validation/test, bổ sung macro-F1 để xem xét chênh lệch giữa các lớp và confusion matrix để phân tích lỗi. Bên cạnh chất lượng dự đoán, nhóm ghi nhận thời gian huấn luyện, số tham số có thể cập nhật (trainable parameters) và thông tin tài nguyên GPU. Việc chọn mô hình dựa trên validation, còn test chỉ được sử dụng để báo cáo kết quả cuối cùng. Các kết quả định lượng và biểu đồ so sánh thuộc phạm vi A1.2, không được suy diễn trước ở giai đoạn A1.1.

5 Kết luận và kế hoạch tiếp theo

Báo cáo A1.1 xác định CIFAR-100 làm bộ dữ liệu chính với phân chia 45.000 ảnh train, 5.000 ảnh validation và 10.000 ảnh test, theo chiến lược stratified và seed 42. Hai mô hình được chọn là ResNet-18 và ViT-Tiny; kế hoạch gồm tám cấu hình đại diện cho from-scratch, pretrained và ba mức độ freeze/fine-tune. Những quyết định này tạo nền tảng cho giai đoạn A1.2, khi nhóm sẽ triển khai DataLoader, khóa cấu hình checkpoint/augmentation, huấn luyện các mô hình, thu thập số liệu và thảo luận sự đánh đổi giữa chất lượng phân loại và chi phí tính toán.

References

[1] A. Krizhevsky, *Learning Multiple Layers of Features from Tiny Images*, 2009. `https://www.cs.toronto.edu/~kriz/cifar.html`

[2] K. He et al., *Deep Residual Learning for Image Recognition*, CVPR, 2016.

[3] A. Dosovitskiy et al., *An Image is Worth 16x16 Words: Transformers for Image Recognition at Scale*, ICLR, 2021.